R中基本数据类型及操作

周世祥

2020年5月17日

R 中的数据类型

电影数据

```
rm(list = ls())
movie = read.csv(" 电影数据.csv", header = T, fileEncoding = "UTF-8")
head(movie)
```

##				name b	oxoffice	douba	anscore	type	duration	showtime
##	1		ı	叶问3	77060.44		6.4	动作	105	2016/3/4
##	2		美	人鱼 3	38583.26		6.9	喜剧	93	2016/2/8
##	3		女汉子真爱	公式	6184.45		4.5	喜剧	93	2016/3/18
##	4	西游记之:	孙悟空三打白	骨精 1	19956.51		5.7	喜剧	120	2016/2/8
##	5		澳门风	云三 1	11693.89		4.0	喜剧	112	2016/2/8
##	6		功夫	熊猫3	99832.53		7.7	喜剧	95	2016/1/29
##		director	star1	index1	£	star2	index2			
##	1	叶伟信	甄子丹	11385		张晋	4105			
##	2	周星驰	邓超	41310		林允	9292			
##	3	郭大雷	赵丽颖	181979		张翰	44277			
##	4	郑保瑞	郭富城	12227		巩俐	8546			
##	5	王晶	周润发	16731	刘] 德华	30277			
##	6	吕寅荣	杰克布莱克	178	安吉丽娜	8 朱莉	1540			

电影数据示例 2

基本数据类型

1. 数值型

电影数据示例

```
class(movie$"boxoffice");
## [1] "numeric"
class(movie$doubanscore)
## [1] "numeric"
# 自己为变量赋一个数值
a = 2; class(a)
## [1] "numeric"
exp(1000) # 正无穷
## [1] Inf
-10 / 0 # 负无穷
## [1] -Inf
exp(1000) / exp(990) # NaN 类型
## [1] NaN
exp(10)
## [1] 22026.47
## [1] 22026.47
```

2. 字符型

字符的定义

```
a = "2"
class(a)
```

[1] "character"

判断电影数据集中,变量"type","name"是不是字符型变量
class(movie\$type)

[1] "character"

class(movie\$name)

[1] "character"

3. 逻辑型数据

读入数据时设置把字符数据保留,不转换为 factor

```
movie = read.csv(" 电影数据.csv", header = T, stringsAsFactors = F, fileEncoding = "UTF-8")
movie$type[movie$name == " 美人鱼"] == " 喜剧"

## [1] TRUE

# 想在数据集中挑选大于 7 分的喜剧电影 name?
movie$name[movie$type == " 喜剧" & movie$"doubanscore" > 7]

## [1] "功夫熊猫3"

# 逻辑语句加减
(1 == 2) + (3 < 4)

## [1] 1
```

4. 因子型数据

(1) 什么是因子型数据

```
(genders = factor(c(" 男", " 女", " 女", " 男", " 男", " 男")))

## [1] 男 女 女 男 男

## Levels: 男 女

(class = factor(c("Poor", "Improved", "Excellent"), ordered = T))

## [1] Poor Improved Excellent

## Levels: Excellent < Improved < Poor
```

输入原始字符变量 4

(2) 如何改变因子型数据各水平的编码顺序 ##"'

```
## [1] Poor Improved Excellent
## Levels: Poor < Improved < Excellent</pre>
```

(3) 如何正确将因子型数据和字符型数据互相转化

输入原始字符变量

```
all = c(" 男", " 女", " 女", " 男", " 男")
# 将字符型变量变成因子型
gender = as.factor(all)
# 变换后的数据类型
is.factor(gender)
## [1] TRUE
class(gender)
## [1] "factor"
# 将因子型变量变成字符型
genders = as.character(gender)
# 变换后的数据类型
is.character(genders)
## [1] TRUE
class(genders)
## [1] TRUE
```

- 5. 时间类数据
- (1) 如何把字符转化成 Date 日期格式

函数 head 用来查看数据前 6 个元素,函数 class 用来查看对象数据类型

```
head(movie$showtime)
## [1] "2016/3/4" "2016/2/8" "2016/3/18" "2016/2/8" "2016/2/8" "2016/1/29"
class(movie$showtime)
## [1] "character"
movie$showtime = as.Date(movie$showtime)
head(movie$showtime)
## [1] "2016-03-04" "2016-02-08" "2016-03-18" "2016-02-08" "2016-02-08"
## [6] "2016-01-29"
class(movie$showtime)
## [1] "Date"
Sys.setlocale("LC_TIME", "C")
## [1] "C"
x = c("1jan1960", "2jan1960", "31mar1960", "30jul1960")
# y = as.Date(x)
(y = as.Date(x, format = "%d%b%Y"))
## [1] "1960-01-01" "1960-01-02" "1960-03-31" "1960-07-30"
```

(2) 如何把字符转化成 POSIXct/POSIXlt 时间格式

```
as.POSIXct("2015-11-27 01:30:00")

## [1] "2015-11-27 01:30:00 CST"

# as.POSIXct("November-27-2015 01:30:00")

as.POSIXct("November-27-2015 01:30:00", format = "%B-%d-%Y %H:%M:%S")
```

```
## [1] "2015-11-27 01:30:00 CST"
```

(3) 如何把时间数据摆弄成你想要的形式

```
(m = head(movie showtime)) # 原始日期数据
## [1] "2016-03-04" "2016-02-08" "2016-03-18" "2016-02-08" "2016-02-08"
## [6] "2016-01-29"
format(m, format = "%B %d %Y") # 改成月日年的格式
## [1] "March 04 2016"
                        "February 08 2016" "March 18 2016"
                                                            "February 08 2016"
## [5] "February 08 2016" "January 29 2016"
format(m, format = "%B %d %Y %A") # 加入星期信息
## [1] "March 04 2016 Friday" "February 08 2016 Monday"
## [3] "March 18 2016 Friday" "February 08 2016 Monday"
## [5] "February 08 2016 Monday" "January 29 2016 Friday"
format(m, format = "%B") # 只提取出月份信息
## [1] "March" "February" "March" "February" "February" "January"
Sys.time() # 输出系统时间
## [1] "2021-05-31 16:12:47 CST"
class(Sys.time()) # 查看时间类型
## [1] "POSIXct" "POSIXt"
format(Sys.time(), format = "%B %d %Y") # 提取部分时间信息
## [1] "May 31 2021"
format(Sys.time(), format = "%Y/%B/%a %H:%M:%S") # 提取部分时间信息
## [1] "2021/May/Mon 16:12:47"
```

(4) 一款处理时间数据的专用包 lubridate

```
# install.packages(lubridate)
library(lubridate)
```

```
## Warning: package 'lubridate' was built under R version 4.0.5
## Attaching package: 'lubridate'
## The following objects are masked from 'package:base':
##
##
      date, intersect, setdiff, union
ymd(x)
## [1] "2009-01-01" "2009-01-02" "2009-01-03" "2009-01-04" "2009-01-05"
## [6] "2009-01-06" "2009-01-07"
mday(as.Date("2015-11-20"))
## [1] 20
wday(as.Date("2015-11-20"))
## [1] 6
hour(as.POSIXct("2015-11-20 01:30:00"))
## [1] 1
minute(as.POSIXct("2015-11-20 01:30:00"))
## [1] 30
(5) 时间类数据的操作
#做差
# 求任意两个日期距离的天数
begin = as.Date("2016-03-04")
```

```
end = as.Date("2016-05-08")
```

Time difference of 65 days

(during = end - begin)

```
# 求任意两个日期距离的周数和小时数
difftime(end, begin, units = "weeks")
```

Time difference of 9.285714 weeks

排序 8

```
difftime(end, begin, units = "hours")
```

Time difference of 1560 hours

排序

单独对时间进行排序

```
head(movie$showtime)

## [1] "2016-03-04" "2016-02-08" "2016-03-18" "2016-02-08" "2016-02-08"

## [6] "2016-01-29"

head(sort(movie$showtime))

## [1] "2016-01-29" "2016-02-08" "2016-02-08" "2016-03-04"

## [6] "2016-03-18"
```

对数据表格中的数据按照时间顺序排列,这里只选取前 6 行,部分列做 展示

```
head(movie[order(movie$showtime), c("name", "showtime")])
```

```
## 6 功夫熊猫3 2016-01-29 
## 2 美人鱼 2016-02-08 
## 4 西游记之孙悟空三打白骨精 2016-02-08 
## 5 澳门风云三 2016-02-08 
## 1 叶问3 2016-03-04 
## 3 女汉子真爱公式 2016-03-18
```

2.1 R 中的数据类型 rm(list = ls()) movie = read.csv("电影数据.csv", fileEncoding = "UTF-8", stringsAsFactors = F)

2.1.2 向量

一、基本操作

1. 向量的创建

```
c(1, 1, 1, 2, 3, 3, 1, 2, 4, 1, 2, 4, 4, 2, 3, 4, 1, 2, 3, 4)

## [1] 1 1 1 2 3 3 1 2 4 1 2 4 4 2 3 4 1 2 3 4

c("a", "b", "c", "d")

## [1] "a" "b" "c" "d"

# seq(起始值, 终止值, 步长)

seq(0, 10, by = 2)

## [1] 0 2 4 6 8 10

1:10

## [1] 1 2 3 4 5 6 7 8 9 10

# sample(被抽取的数据集合, 抽取数量)

set.seed(1234)

sample(1:10, 5)

## [1] 10 6 5 4 1

paste0("x_", 1:5)

## [1] "x_1" "x_2" "x_3" "x_4" "x_5"
```

2. 向量的引用

```
# 引用 x 向量中的第 5 个元素
x=c(1, 1, 1, 2, 3, 3)
x[5]
```

[1] 3

```
# 想看看 x 向量中 3 所在的位置
which(x == 3)
```

[1] 5 6

```
which.max(x)
## [1] 5
which.min(x)
## [1] 1
3. 集合运算
intersect(c(1, 2, 3, 3, 12, 4, 123, 12), c(1, 2, 3))
## [1] 1 2 3
union(c("狗熊会", "聚数据英才"), c("狗熊会", "助产业振兴"))
## [1] "狗熊会" "聚数据英才""助产业振兴"
setdiff(10:2, 5:3)
## [1] 10 9 8 7 6 2
二、常见类型
1. 数值向量的花式玩法
# match 函数
x = c(1, 1, 1, 2, 3, 3, 1, 2, 4, 1, 2, 4, 4, 2, 3, 4, 1, 2, 3, 4)
(y = letters[x]) # letters 是一个内置字符串, 里面储存 26 个字母字符
## [1] "a" "a" "a" "b" "c" "c" "a" "b" "d" "a" "b" "d" "d" "d" "b" "c" "d" "a" "b" "c"
## [20] "d"
match(y, letters[1:4])
## [1] 1 1 1 2 3 3 1 2 4 1 2 4 4 2 3 4 1 2 3 4
# cut 函数
(Age = sample(21:100, 20, replace = T))
```

[1] 25 58 36 24 90 99 98 34 76 82 24 24 41 60 76 87 25 86 67 60

```
# 将年龄数据离散化
label = c('壮年', '中年', '长辈', '老年')
(ages = cut(Age, breaks = c(20, 30, 50, 70, 100), labels = label))
## [1] 壮年 长辈 中年 壮年 老年 老年 老年 中年 老年 老年 壮年 壮年 中年 长辈 老年
## [16] 老年 壮年 老年 长辈 长辈
## Levels: 壮年 中年 长辈 老年
# sort 和 order 函数
set.seed(1234)
(x = sample(8, 5))
## [1] 4 2 6 5 8
sort(x)
## [1] 2 4 5 6 8
order(x)
## [1] 2 1 4 3 5
x[order(x)]
## [1] 2 4 5 6 8
2. 字符向量的花式玩法
# nchar 用来提取字符串的长度
nchar("欢迎关注狗熊会")
## [1] 7
# 看看数据集中的电影名字的长度分别是多少
nchar(movie$name)
## [1] 3 3 7 12 5 5 12 7 8 4 5 7 4 4 6 4 4 3 2
# 中英文的字符长度计算方法有不同
```

[1] 29

substr 提取子字符串
substr(" 欢迎关注狗熊会", 1, 4)

nchar("Welcome to follow the CluBear")

思考题 12

```
## [1] "欢迎关注"
substr(" 一懒众衫小", 3, 5)
## [1] "众衫小"
# paste 基本玩法
paste(c(" 双 11", " 是个", " 什么节日"), collapse = "")
## [1] "双11是个什么节日"
paste("A", 1:4)
## [1] "A 1" "A 2" "A 3" "A 4"
# paste 花式玩法
paste(1:4, collapse = "")
## [1] "1234"
paste(1:4, sep="")
## [1] "1" "2" "3" "4"
paste("A", 1:4, sep="_")
## [1] "A_1" "A_2" "A_3" "A_4"
                                   思考题
```

```
paste(LETTERS[1:4], 1:4, collapse = "_")

paste(LETTERS[1:4], 1:4, sep = "_", collapse = "|")

paste(LETTERS[1:4], 1:4)

txt = c("狗熊会", "CluBear", "双11", "生日")

# 返回含有关键字的字符位置
grep("Bear", txt)

gsub("生日", "happy birthday", txt)
```

自己测试一下:

```
# grep返回movie的name中包含 "青春"的行号8, movie[8,]即提取出movie数据集的第8行(index = grep("青春", movie$name))

(young = movie[index, ])

## name boxoffice doubanscore type duration showtime director

# 看看它的豆瓣评分和票房处于我们电影数据集中的什么位置
young$doubanscore > mean(movie$doubanscore)

young$boxoffice > mean(movie$boxoffice)

salary = c("22万", "30万", "50万", "120万", "11万")
(salary0 = gsub("万", "0000", salary))

mean(as.numeric(salary0))

median(as.numeric(salary0)) # 结果是科学计数法的形式
```

1. 矩阵的创建与引用

[3,] 0 0 0

2.1.3 矩阵

生成全部是 0 的矩阵

```
(zero = matrix(0, nrow = 3, ncol = 3))
## [,1] [,2] [,3]
## [1,] 0 0 0
## [2,] 0 0 0
```

```
# 生成一个对角全是 1 的矩阵, 直接在 diag 中输入对角线向量即可
(dig = diag(rep(1, 4)))
## [,1] [,2] [,3] [,4]
## [1,] 1 0 0 0
## [2,] 0 1 0 0
## [3,] 0 0 1 0
## [4,] 0 0 0 1
# 从已有数据转化成矩阵
(M = matrix(1:12, nrow = 3, ncol = 4))
## [,1] [,2] [,3] [,4]
## [1,] 1 4 7 10
## [2,] 2 5 8 11
## [3,] 3 6 9 12
(N = diag(1:4))
## [,1] [,2] [,3] [,4]
## [1,] 1 0 0 0
## [2,] 0 2 0 0
## [3,] 0 0 3 0
## [4,] 0 0 0 4
```

2. 矩阵的常用操作

(1) 矩阵概览

```
# 查看矩阵的维度 dim(M)
```

[1] 3 4

```
# 提取矩阵的行数
nrow(M)
```

[1] 3

```
# 提取矩阵的列数
ncol(M)
```

[1] 4

```
# 引用元素
M[1, 2]
## [1] 4
M[1:2, 2:3]
## [,1] [,2]
## [1,] 4 7
## [2,] 5 8
# 给行列命名
colnames(M) = paste0("x_", 1:4)
rownames(M) = 1:3; M
## x_1 x_2 x_3 x_4
## 1 1 4 7 10
## 2 2 5 8 11
## 3 3 6 9 12
# 同样的命令可调用行列名
colnames(M)
## [1] "x_1" "x_2" "x_3" "x_4"
rownames(M)
## [1] "1" "2" "3"
(2) 将多个矩阵合并
(A = matrix(1:9, nrow = 3, ncol = 3, byrow = T))
## [,1] [,2] [,3]
## [1,] 1 2 3
## [2,] 4 5 6
## [3,] 7 8 9
(B = diag(11:13))
## [,1] [,2] [,3]
## [1,] 11 0 0
## [2,] 0 12 0
```

[3,] 0 0 13

rbind(A, B)

```
## [,1] [,2] [,3]

## [1,] 1 2 3

## [2,] 4 5 6

## [3,] 7 8 9

## [4,] 11 0 0

## [5,] 0 12 0

## [6,] 0 0 13
```

cbind(A, B)

```
## [,1] [,2] [,3] [,4] [,5] [,6]
## [1,] 1 2 3 11 0 0
## [2,] 4 5 6 0 12 0
## [3,] 7 8 9 0 0 13
```

3. 矩阵的数学操作

(1) 矩阵的加减乘运算

A + B

```
## [,1] [,2] [,3]
## [1,] 12 2 3
## [2,] 4 17 6
## [3,] 7 8 22
```

A - B

[,1] [,2] [,3] ## [1,] -10 2 3 ## [2,] 4 -7 6 ## [3,] 7 8 -4

A * B

[,1] [,2] [,3] ## [1,] 11 0 0 ## [2,] 0 60 0 ## [3,] 0 0 117

A **%*%** B

11

[,1] [,2] [,3]

24

39

78

##

##

##

##

system.time(eigs(T, 5))

0.19

user system elapsed

0.19

0.00

[1,]

```
## [2,] 44 60
## [3,] 77 96 117
(2) rARPACK 的应用
# 打开这个包
# install.packages("rARPACK")
library(rARPACK)
## Warning: package 'rARPACK' was built under R version 4.0.5
#构造一个 1000 维的大型矩阵
T = matrix(1:1000000, 1000, 1000)
# 正常分解与快速分解的对比, 此处以选择前 5 个特征(奇异)值为例
system.time(svd(T))
##
     user system elapsed
##
     2.41
            0.00
                    2.41
system.time(svds(T, 5))
##
     user system elapsed
##
     0.06
                    0.06
            0.00
system.time(eigen(T))
##
     user system elapsed
     4.00
            0.01
```

矩阵的转置、求逆及分解

```
solve(B) # 求矩阵逆
##
             [,1]
                       [,2]
                                  [,3]
```

```
## [1,] 0.09090909 0.00000000 0.00000000
## [2,] 0.00000000 0.08333333 0.00000000
## [3,] 0.00000000 0.00000000 0.07692308
t(A) # 求矩阵转置
## [,1] [,2] [,3]
## [1,] 1 4 7
## [2,] 2 5 8
## [3,] 3 6
eigen(A) # 特征值分解
## eigen() decomposition
## $values
## [1] 1.611684e+01 -1.116844e+00 -1.303678e-15
##
## $vectors
##
            [,1] [,2]
                                  [,3]
## [1,] -0.2319707 -0.78583024 0.4082483
## [2,] -0.5253221 -0.08675134 -0.8164966
## [3,] -0.8186735  0.61232756  0.4082483
## eigen() decomposition
## $values
svd(A) # 奇异值 svd 分解
## $d
## [1] 1.684810e+01 1.068370e+00 4.418425e-16
##
## $u
##
            [,1] [,2] [,3]
## [1,] -0.2148372  0.8872307  0.4082483
## [2,] -0.5205874  0.2496440 -0.8164966
## [3,] -0.8263375 -0.3879428 0.4082483
##
## $v
            [,1]
                 [,2]
                                  [,3]
##
## [1,] -0.4796712 -0.77669099 -0.4082483
## [2,] -0.5723678 -0.07568647 0.8164966
## [3,] -0.6650644   0.62531805 -0.4082483
```

(3) 稀疏矩阵

```
# install.packages("Matrix")
library(Matrix)
# 生成普通矩阵
vector = c(1:3, rep(0, 5), 6:9)
(m1 = matrix(vector, nrow = 3, ncol = 4))
     [,1] [,2] [,3] [,4]
##
## [1,]
       1
           0
## [2,]
       2
           0
               0
                  8
## [3,]
       3
           0
               6
                  9
# 生成稀疏矩阵方法 1
(m2 = Matrix(vector, nrow = 3 ,ncol = 4, sparse = TRUE))
## 3 x 4 sparse Matrix of class "dgCMatrix"
##
## [1,] 1 . . 7
## [2,] 2 . . 8
## [3,] 3 . 6 9
(m3 = Matrix(vector, nrow = 3 ,ncol = 4, sparse = FALSE))
## 3 x 4 Matrix of class "dgeMatrix"
     [,1] [,2] [,3] [,4]
## [1,]
       1
           0
## [2,]
       2
           0
               0
                  8
## [3,]
       3
         0
               6
                  9
# 生成稀疏矩阵方法 2
(m4 = spMatrix(10, 20, i = c(1, 3:8), j = c(2, 9, 6:10), x = 7 * (1:7)))
## 10 x 20 sparse Matrix of class "dgTMatrix"
##
##
  [1,] . 7 . . . . . . .
##
  [7,] . . . . . . . . 42
```

```
summary(m4)
## 10 x 20 sparse Matrix of class "dgTMatrix", with 7 entries
## i j x
## 1 1 2 7
## 2 3 9 14
## 3 4 6 21
## 4 5 7 28
## 5 6 8 35
## 6 7 9 42
## 7 8 10 49
# 当行列数分别为 10000 时,稀疏矩阵的内存大小和生成时间优势均很明显。
n = 10000
m1 = matrix(0, nrow = n, ncol = n)
m2 = Matrix(0, nrow = n, ncol = n, sparse = TRUE)
object.size(m1); object.size(m2)
## 800000216 bytes
## 41728 bytes
system.time(matrix(0, nrow = n, ncol = n))
##
    user system elapsed
##
    0.15
           0.03
system.time(Matrix(0, nrow = n, ncol = n, sparse = TRUE))
##
    user system elapsed
##
       0
             0
# 两种矩阵计算区别
n = 1000
dat = sample(c(0, 1), n^2, replace = TRUE, prob = c(0.9, 0.1))
m1 = matrix(dat, nrow = n, ncol = n); m1[1:6, 1:6]
      [,1] [,2] [,3] [,4] [,5] [,6]
## [1,]
            0
                    0
        0
                0
                        0
## [2,]
            0
                0
                    0
                        0
                            0
        0
```

[1] "data.frame"

```
## [3,]
       0 1 0 0 0 0
## [4,] 0 1
## [5,] 0 0 0 0 0
## [6,] 0 0 1 1 0
m2 = Matrix(dat, nrow = n, ncol = n, sparse = TRUE); m2[1:6, 1:6]
## 6 x 6 sparse Matrix of class "dgCMatrix"
##
## [1,] . . . . .
## [2,] . . . . . .
## [3,] . 1 . . . .
## [4,] . 1 . 1 . 1
## [5,] . . . . .
## [6,] . . 1 1 . .
# 求乘积运算时间对比
system.time(m1 %*% t(m1))
##
     user system elapsed
      0.7 0.0
##
                   0.7
system.time(m2 %*% t(m1))
##
     user system elapsed
##
     0.07 0.00
                  0.06
rm(list = ls())
2.1 R 中的数据类型
2.1.4 数据框
1. 创建数据框
# 读入一个 txt,csv 等格式数据,即自成一个数据框
movie = read.csv(" 电影数据.csv", fileEncoding = "UTF-8", stringsAsFactors = F)
class(movie)
```

自己创建

```
star1 = c(" 邓超", " 赵丽颖", " 郭富城", " 周润发", " 杰克布莱克", " 汤唯", " 白敬亭", " 陈晓", " 梁家birthyear = c(1979, 1987, 1965, 1955, 1969, 1979, 1993, 1987, 1958, 1979, 1987, 1980, 1977) gender = c(" 男", " 女", " 男", " 男", " 女", " 男", " 别",
```

```
##
        star1 birthyear gender
         邓超
                  1979
                          男
## 1
       赵丽颖
                  1987
                          女
## 2
       郭富城
                          男
## 3
                 1965
       周润发
                          男
                 1955
## 4
## 5 杰克布莱克
                          男
                 1969
         汤唯
                      女
## 6
                 1979
```

2. 汇总

str(movie)

```
## 'data.frame':
                 19 obs. of 11 variables:
              : chr "叶问3" "美人鱼" "女汉子真爱公式" "西游记之孙悟空三打白骨精" ...
## $ name
## $ boxoffice : num 77060 338583 6184 119957 111694 ...
## $ doubanscore: num 6.4 6.9 4.5 5.7 4 7.7 6.5 6.4 5 5.6 ...
              : chr "动作" "喜剧" "喜剧" "喜剧" ...
   $ type
##
## $ duration : int 105 93 93 120 112 95 131 108 95 102 ...
## $ showtime : chr "2016/3/4" "2016/2/8" "2016/3/18" "2016/2/8" ...
              : chr "叶伟信" "周星驰" "郭大雷" "郑保瑞" ...
## $ director
              : chr "甄子丹" "邓超" "赵丽颖" "郭富城" ...
## $ star1
## $ index1
              : int 11385 41310 181979 12227 16731 178 13499 14759 13251 6911 ...
              : chr "张晋" "林允" "张翰" "巩俐" ...
## $ star2
              : int 4105 9292 44277 8546 30277 1540 77260 755 9549 5614 ...
##
  $ index2
summary(movie)
```

```
##
       name
                      boxoffice
                                      doubanscore
                                                        type
                    Min. : 924.9 Min.
## Length:19
                                            :3.400
                                                    Length:19
## Class :character
                    1st Qu.: 3799.5 1st Qu.:4.600
                                                    Class : character
   Mode :character
                    Median: 12561.5 Median: 5.300
                                                    Mode :character
##
                    Mean : 50813.3 Mean :5.568
##
                    3rd Qu.: 77700.9
##
                                      3rd Qu.:6.450
##
                    Max. :338583.3
                                      Max. :8.000
```

```
duration
##
                    showtime
                                     director
                                                        star1
##
   Min.
          : 84.0
                Length: 19
                                   Length:19
                                                     Length:19
   1st Qu.: 94.5
                  ##
                                                     Class : character
   Median: 99.0
                  Mode :character
                                   Mode :character
                                                     Mode :character
##
##
   Mean
        :101.5
##
   3rd Qu.:107.5
##
   Max.
          :131.0
                     star2
                                        index2
##
       index1
##
   Min. : 178
                   Length:19
                                    Min. : 521
   1st Qu.: 8232
                   Class :character
                                    1st Qu.: 3650
##
   Median : 12227
                   Mode :character
                                    Median: 9292
##
## Mean
          : 27861
                                    Mean
                                           :17369
## 3rd Qu.: 24663
                                    3rd Qu.:20763
## Max.
          :181979
                                    Max.
                                           :77260
head(movie)
```

```
##
                    name boxoffice doubanscore type duration showtime
                    叶问3 77060.44
                                        6.4 动作
## 1
                                                    105 2016/3/4
## 2
                   美人鱼 338583.26
                                        6.9 喜剧
                                                     93 2016/2/8
## 3
            女汉子真爱公式
                          6184.45
                                       4.5 喜剧
                                                     93 2016/3/18
## 4 西游记之孙悟空三打白骨精 119956.51
                                       5.7 喜剧
                                                    120 2016/2/8
## 5
                澳门风云三 111693.89
                                        4.0 喜剧
                                                    112 2016/2/8
## 6
                功夫熊猫3 99832.53
                                        7.7 喜剧
                                                     95 2016/1/29
##
    director
               star1 index1
                                star2 index2
               甄子丹 11385
     叶伟信
## 1
                                 张晋
                                       4105
     周星驰
                邓超 41310
                                 林允
## 2
                                       9292
     郭大雷
               赵丽颖 181979
                                 张翰 44277
## 3
## 4
     郑保瑞
               郭富城 12227
                                 巩俐
                                       8546
      王晶
                               刘德华
## 5
               周润发 16731
                                      30277
    吕寅荣 杰克布莱克 178 安吉丽娜朱莉
## 6
                                       1540
```

3. 变大-数据框的增列、合并

```
#添加一列数据 prefer
prefer = 1:19
movie$pre = prefer
head(movie)
```

2 赵丽颖 女汉子真爱公式

2 181979 张翰 44277

3 甄子丹

1 41310 林允

3 11385 张晋

##

```
## 1
                     叶问3 77060.44
                                         6.4 动作
                                                      105 2016/3/4
                    美人鱼 338583.26
## 2
                                         6.9 喜剧
                                                      93 2016/2/8
             女汉子真爱公式
## 3
                           6184.45
                                         4.5 喜剧
                                                      93 2016/3/18
## 4 西游记之孙悟空三打白骨精 119956.51
                                         5.7 喜剧
                                                      120 2016/2/8
## 5
                澳门风云三 111693.89
                                         4.0 喜剧
                                                      112 2016/2/8
                 功夫熊猫3 99832.53
                                         7.7 喜剧
## 6
                                                      95 2016/1/29
##
    director
                star1 index1
                                 star2 index2 pre
               甄子丹 11385
## 1
      叶伟信
                                   张晋
                                         4105
                 邓超 41310
## 2
      周星驰
                                   林允
                                         9292
                                               2
      郭大雷
               赵丽颖 181979
                                   张翰
## 3
                                        44277
                                               3
               郭富城 12227
                                   巩俐
      郑保瑞
## 4
                                         8546
                                               4
## 5
       王晶
               周润发 16731
                                 刘德华
                                        30277
                                               5
## 6
      吕寅荣 杰克布莱克
                        178 安吉丽娜朱莉
                                         1540
                                               6
# merge 实现的效果是:将 movie 和 stars 按照列 star1 匹配并合并起来
(movie.star = merge(movie[1:3, ], stars,by = "star1"))
##
     star1
                   name boxoffice doubanscore type duration showtime director
## 1
                 美人鱼 338583.26
      邓超
                                       6.9 喜剧
                                                    93 2016/2/8
                                                                 周星驰
## 2 赵丽颖 女汉子真爱公式
                         6184.45
                                       4.5 喜剧
                                                    93 2016/3/18
                                                                 郭大雷
    index1 star2 index2 pre birthyear gender
## 1 41310 林允
                 9292
                       2
                             1979
## 2 181979 张翰 44277
                                     女
                       3
                             1987
# all. x=T, 即取前一个数据框 movie 中 star1 列所有的值做合并, 匹配不到赋值 NA
(movie.star = merge(movie[1:3, ], stars[1:5, ], by = "star1", all.x = T))
##
     star1
                   name boxoffice doubanscore type duration showtime director
     邓超
                 美人鱼 338583.26
                                       6.9 喜剧
                                                    93 2016/2/8
                                                                 周星驰
```

4.5 喜剧

6.4 动作

男

女

<NA>

93 2016/3/18

105 2016/3/4

郭大雷

叶伟信

6184.45

1979

1987

NA

叶问3 77060.44

2

3

1

index1 star2 index2 pre birthyear gender

9292

4105

4. 变小-数据的筛选、引用

引用

```
movie[3,] # 查看第 3 行的电影信息
          name boxoffice doubanscore type duration showtime director star1
##
## 3 女汉子真爱公式
                6184.45
                           4.5 喜剧 93 2016/3/18 郭大雷 赵丽颖
## index1 star2 index2 pre
## 3 181979 张翰 44277 3
movie[, 8] # 查看第 8 列主演者的名字
                         "赵丽颖"
## [1] "甄子丹"
              "邓超"
                                   "郭富城"
                                            "周润发"
## [6] "杰克布莱克" "汤唯"
                         "白敬亭"
                                   "陈晓"
                                            "梁家辉"
## [11] "姚晨"
               "宋茜"
                         "黄宗泽"
                                   "黄晓明"
                                            "洪金宝"
## [16] "陈坤"
              "陶泽如"
                         "刘亦菲"
                                   "何润东"
# 筛选
movie$star1 #用$符号通过列名引用
## [1] "甄子丹"
              "邓超"
                         "赵丽颖"
                                   "郭富城"
                                            "周润发"
## [6] "杰克布莱克" "汤唯"
                         "白敬亭"
                                  "陈晓"
                                            "梁家辉"
## [11] "姚晨"
               "宋茜"
                         "黄宗泽"
                                  "黄晓明"
                                            "洪金宝"
## [16] "陈坤"
              "陶泽如"
                        "刘亦菲"
                                   "何润东"
(action = movie[movie$type == " 动作",]) # 选择数据中的动作电影
          name boxoffice doubanscore type duration showtime director star1
##
                                                  叶伟信 甄子丹
         叶问3 77060.44
                          6.4 动作
## 1
                                     105 2016/3/4
## 10
       冰河追凶
              4262.14
                           5.6 动作
                                     102 2016/4/15
                                                  徐伟 梁家辉
## 15 我的特工爷爷 32009.37
                                     99 2016/4/1 洪金宝 洪金宝
                          5.3 动作
          钢刀
                924.86
                          4.3 动作
                                     94 2016/5/20 阿甘 何润东
## 19
    index1 star2 index2 pre
##
           张晋
## 1
   11385
                4105
## 10 6911 佟大为
               5614 10
## 15
    9148 刘德华 30277 15
## 19 11822 李学东
```

(action_long = movie[movie\$type == " 动作" & movie\$duration > 100,]) # 放映时间超过 100 分钟的动作

name boxoffice doubanscore type duration showtime director star1

521 19

##

```
## 1
       叶问3 77060.44
                        6.4 动作
                                     105 2016/3/4
                                                   叶伟信 甄子丹
                         5.6 动作
## 10 冰河追凶
             4262.14
                                                    徐伟 梁家辉
                                      102 2016/4/15
    index1 star2 index2 pre
     11385
           张晋
                 4105
## 1
      6911 佟大为
## 10
                 5614 10
```

5. 变序-数据框的内部排序

按照票房降序排列

movie = movie[order(movie\$boxoffice, decreasing = T),]; head(movie)

```
##
                    name boxoffice doubanscore type duration showtime
                   美人鱼 338583.26
## 2
                                     6.9 喜剧
                                                   93 2016/2/8
                                      5.7 喜剧
## 4 西游记之孙悟空三打白骨精 119956.51
                                                   120 2016/2/8
               澳门风云三 111693.89
## 5
                                       4.0 喜剧
                                                  112 2016/2/8
                功夫熊猫3 99832.53
                                      7.7 喜剧
## 6
                                                   95 2016/1/29
## 7 北京遇上西雅图之不二情书 78341.38
                                      6.5 喜剧
                                                  131 2016/4/29
## 1
                   叶问3 77060.44
                                       6.4 动作
                                                  105 2016/3/4
##
    director
               star1 index1
                               star2 index2 pre
## 2
     周星驰
                邓超 41310
                                林允
                                      9292
     郑保瑞
              郭富城 12227
                                巩俐
## 4
                                      8546
      王晶
             周润发 16731
                              刘德华
## 5
                                     30277
    吕寅荣 杰克布莱克 178 安吉丽娜朱莉
                                      1540
     薛晓路
                汤唯 13499
## 7
                               吴秀波 77260
                                           7
     叶伟信
              甄子丹 11385
                                 张晋
## 1
                                      4105
```

先按电影类型排序,再按照豆瓣评分排序

movie = movie[order(movie\$type, movie\$doubanscore, decreasing = T),]; head(movie)

```
name boxoffice doubanscore type duration showtime
##
                 功夫熊猫3 99832.53
                                         7.7 喜剧
## 6
                                                      95 2016/1/29
                    美人鱼 338583.26
## 2
                                         6.9 喜剧
                                                      93 2016/2/8
    北京遇上西雅图之不二情书 78341.38
                                         6.5 喜剧
                                                     131 2016/4/29
     西游记之孙悟空三打白骨精 119956.51
                                         5.7 喜剧
                                                     120 2016/2/8
                  刑警兄弟
## 13
                           3005.96
                                         5.2 喜剧
                                                     97 2016/4/22
             女汉子真爱公式
## 3
                           6184.45
                                         4.5 喜剧
                                                     93 2016/3/18
                star1 index1
##
     director
                                 star2 index2 pre
      吕寅荣 杰克布莱克
                       178 安吉丽娜朱莉
                                        1540
## 6
                                              6
      周星驰
                 邓超 41310
                                  林允
                                        9292
## 2
                                              2
      薛晓路
                 汤唯 13499
                              吴秀波 77260
                                              7
## 7
```

```
郭富城 12227
      郑保瑞
                              巩俐
                                    8546
## 4
                                         4
     戚家基
              黄宗泽
                     9823
                              金刚
## 13
                                   4010 13
     郭大雷 赵丽颖 181979
## 3
                              张翰 44277
                                         3
```

6. 变形-长宽表互换

```
# install.packages("reshape")
library(reshape)
## Warning: package 'reshape' was built under R version 4.0.5
##
## Attaching package: 'reshape'
## The following object is masked from 'package:Matrix':
##
##
      expand
## The following object is masked from 'package:lubridate':
##
##
      stamp
# install.packages("reshape2")
library(reshape2)
## Warning: package 'reshape2' was built under R version 4.0.5
##
## Attaching package: 'reshape2'
## The following objects are masked from 'package:reshape':
##
##
      colsplit, melt, recast
## (1) 宽表变长表 ##
mWide = data.frame(Name = c(" 熊大", " 水妈"), Type = c(" 帅哥", " 美女"),
                  GF2013 = c(300, 100), GF2014 = c(500, 350), GF2015 = c(1000, 886))
# 由于构造数据框时列名不可以为纯数字, 在数字前添加 GF
# 将列名中的 GF 去掉
colnames(mWide)[3:5] = gsub("GF", "", colnames(mWide)[3:5])
mWide # 查看原表
```

Name Type 2013 2014 2015

```
## 1 熊大 帅哥 300 500 1000
## 2 水妈 美女 100 350 886
(mLong = reshape::melt(mWide, id.vars = c("Name", "Type"), variable_name = "Year"))
    Name Type Year value
## 1 熊大 帅哥 2013
                   300
## 2 水妈 美女 2013
                   100
## 3 熊大 帅哥 2014
                   500
## 4 水妈 美女 2014
                   350
## 5 熊大 帅哥 2015 1000
## 6 水妈 美女 2015
                   886
#将列 Year 从字符型变成数值型
mLong$Year = as.numeric(mLong$Year)
# 长表变宽表
reshape2::dcast(mLong, Name + Type ~ Year)
##
    Name Type 1
                       3
## 1 水妈 美女 100 350 886
## 2 熊大 帅哥 300 500 1000
7.R 中的数据透视表-神奇的 ddply
Excel 中,常用的功能是 vlookup 和数据透视表,在 R 中,ddply 函数可以完成类似数据透视表的分组
计算不同量的功能。
# install.packages(plyr)
library(plyr)
## Warning: package 'plyr' was built under R version 4.0.5
##
## Attaching package: 'plyr'
## The following objects are masked from 'package:reshape':
##
      rename, round_any
##
# 根据电影类型进行分组,查看不同类型电影票房的平均水平
popular_type = ddply(movie, .(type), function(x) {mean(x$boxoffice)}); head(popular_type)
```

##

type

۷1

```
## 1 爱情 11206.95
## 2 动作 28564.20
## 3 犯罪 36624.84
## 4 剧情 6671.91
## 5 喜剧 95116.85
# 根据电影类型和电影时长同时分组,查看电影票房的平均水平
long = ddply(movie, .(type,duration), function(x) {mean(x$index1)}); head(long)
    type duration
##
                   ۷1
## 1 爱情
            84 58355
## 2 爱情
            95 13251
## 3 爱情
           108 14759
## 4 动作
            94 11822
## 5 动作
            99 9148
## 6 动作
         102 6911
rm(list = ls())
```

2.1 R 中的数据类型

2.1.5 列表

1. 创建

```
(example = list("abc", 3:5, matrix(1, nrow = 3, ncol = 4), data.frame(x = 1:4, y = paste0("boy_",
## [[1]]
## [1] "abc"
##
## [[2]]
## [1] 3 4 5
##
## [[3]]
      [,1] [,2] [,3] [,4]
##
## [1,]
         1
               1
## [2,]
         1
               1
                         1
## [3,]
        1
             1
                         1
##
```

```
## [[4]]
## x
          У
## 1 1 boy_1
## 2 2 boy_2
## 3 3 boy_3
## 4 4 boy_4
### 2. 基本操作 ###
# 查看
(complex = list(first = list(1:2), second = list(letters, list(matrix(1:4, nrow = 2, ncol = 2)))))
## $first
## $first[[1]]
## [1] 1 2
##
##
## $second
## $second[[1]]
## [1] "a" "b" "c" "d" "e" "f" "g" "h" "i" "j" "k" "l" "m" "n" "o" "p" "q" "r" "s"
## [20] "t" "u" "v" "w" "x" "y" "z"
##
## $second[[2]]
## $second[[2]][[1]]
       [,1] [,2]
## [1,]
        1
## [2,]
          2
# 利用名字引用元素
complex$first
## [[1]]
## [1] 1 2
# 利用序号引用元素
complex[[1]]
## [[1]]
## [1] 1 2
# 利用序号添加元素
complex[[3]] = matrix(1, 2, 3); complex
```

\$first

```
## $first[[1]]
## [1] 1 2
##
##
## $second
## $second[[1]]
## [1] "a" "b" "c" "d" "e" "f" "g" "h" "i" "j" "k" "l" "m" "n" "o" "p" "q" "r" "s"
## [20] "t" "u" "v" "w" "x" "y" "z"
##
## $second[[2]]
## $second[[2]][[1]]
       [,1] [,2]
## [1,] 1
## [2,]
          2
##
##
##
## [[3]]
      [,1] [,2] [,3]
## [1,]
         1
               1
## [2,]
        1
               1
# 利用名字添加元素
complex$new = 1:5; complex
## $first
## $first[[1]]
## [1] 1 2
##
##
## $second
## $second[[1]]
## [1] "a" "b" "c" "d" "e" "f" "g" "h" "i" "j" "k" "l" "m" "n" "o" "p" "q" "r" "s"
## [20] "t" "u" "v" "w" "x" "y" "z"
##
## $second[[2]]
## $second[[2]][[1]]
       [,1] [,2]
## [1,]
          1
## [2,]
          2
```

```
##
##
##
## [[3]]
      [,1] [,2] [,3]
##
## [1,]
         1
## [2,]
            1
        1
##
## $new
## [1] 1 2 3 4 5
3. 列表中的 **ply 函数 ###
# 老王耗子药的单价,单位 (元/袋)
(price = list(year2014 = 36:33, year2015 = 32:35, year2016 = 30:27))
## $year2014
## [1] 36 35 34 33
##
## $year2015
## [1] 32 33 34 35
##
## $year2016
## [1] 30 29 28 27
# lapply 返回列表
lapply(price, mean)
## $year2014
## [1] 34.5
##
## $year2015
## [1] 33.5
##
## $year2016
## [1] 28.5
lapply(price, sd)
## $year2014
## [1] 1.290994
```

```
##
## $year2015
## [1] 1.290994
##
## $year2016
## [1] 1.290994
lapply(price, quantile)
## $year2014
     0%
          25% 50% 75% 100%
## 33.00 33.75 34.50 35.25 36.00
##
## $year2015
     0%
          25% 50% 75% 100%
## 32.00 32.75 33.50 34.25 35.00
##
## $year2016
##
     0%
          25% 50% 75% 100%
## 27.00 27.75 28.50 29.25 30.00
# sapply 默认返回向量或矩阵
sapply(price, mean)
## year2014 year2015 year2016
      34.5
             33.5
                       28.5
sapply(price, sd)
## year2014 year2015 year2016
## 1.290994 1.290994 1.290994
sapply(price, quantile)
       year2014 year2015 year2016
##
## 0%
          33.00
                  32.00
                          27.00
## 25%
          33.75 32.75
                        27.75
## 50%
          34.50 33.50 28.50
                34.25 29.25
## 75%
          35.25
                  35.00 30.00
## 100%
          36.00
# mapply 实现了将 price 与 amount 对应元素相乘的效果
(amount = list(year2014 = rep(200, 4), year2015 = rep(100, 4), year2016 = rep(300, 4)))
```

```
## $year2014
## [1] 200 200 200 200
##
## $year2015
## [1] 100 100 100 100
##
## $year2016
## [1] 300 300 300 300
(income_quarter = mapply("*", price, amount))
##
       year2014 year2015 year2016
           7200
## [1,]
                     3200
                              9000
## [2,]
           7000
                    3300
                              8700
## [3,]
           6800
                    3400
                              8400
## [4,]
            6600
                     3500
                              8100
# 练习题: 总收入
(income_year = mapply(function(x, y) {sum(x*y)}, price, amount))
## year2014 year2015 year2016
##
      27600
              13400
                        34200
4.list 对象的其他快捷玩法
```

5 39.95 116.3 熊孩子玩耍基地

地点

经度 纬度

##

##

[[2]]

```
## 1 39.96 116.4 论文生产基地
## 2 39.96 116.4 论文生产基地
## 3 39.96 116.4 论文生产基地
## 4 39.96 116.4 论文生产基地
## 5 39.96 116.4 论文生产基地
## [[3]]
## 经度 纬度 地点
## 1 39.97 116.5 工业实践基地
## 2 39.97 116.5 工业实践基地
## 3 39.97 116.5 工业实践基地
## 4 39.97 116.5 工业实践基地
## 5 39.97 116.5 工业实践基地
```

do.call(rbind, example)

```
经度 纬度
                     地点
##
## 1 39.95 116.3 熊孩子玩耍基地
## 2 39.95 116.3 熊孩子玩耍基地
## 3 39.95 116.3 熊孩子玩耍基地
## 4 39.95 116.3 熊孩子玩耍基地
## 5 39.95 116.3 熊孩子玩耍基地
## 6 39.96 116.4 论文生产基地
## 7 39.96 116.4 论文生产基地
## 8 39.96 116.4 论文生产基地
## 9 39.96 116.4 论文生产基地
## 10 39.96 116.4
              论文生产基地
## 11 39.97 116.5
              工业实践基地
              工业实践基地
## 12 39.97 116.5
              工业实践基地
## 13 39.97 116.5
## 14 39.97 116.5
              工业实践基地
## 15 39.97 116.5
              工业实践基地
```

参考文献

朱雪宁,《R语言从数据思维到数据实战》,中国人民大学出版社,2019